

Анализ связывания Foxd3 на четырёх стадиях развития *Danio rerio*

Домашняя работа по биоинформатике · ChIP-seq

Мархиева Карина Алихановна · МФТИ, ФБМФ · 2026

Цель и данные

Я сравнила участки связывания Foxd3 на стадиях 75 % эпиболии (75ep), 1–2 сомитов (1–2ss), 5–6 сомитов (5–6ss) и 14 сомитов (14ss). Для 75ep, 1–2ss и 14ss использовались предоставленные парные BAM-файлы ChIP и Input. Для 5–6ss я взяла готовые пики, дорожки и графики из каталога преподавателя. Все координаты относятся к сборке GRCz11; названия хромосом в исходных файлах имеют вид NC_....

Обработка данных

Сначала для каждого BAM я посмотрела samtools flagstat. Затем bamCoverage построил ChIP и Input BigWig в CPM с размером бина 10 п. н. С помощью bigwigCompare я получила $\log_2[(\text{ChIP} + 1)/(\text{Input} + 1)]$. MACS3 вызывал пики в режиме BAMPE при эффективном размере генома 1 360 000 000 и пороге $q < 0,01$. FRiP здесь считался как доля выравниваний ChIP BAM, пересекающих пики: samtools view -c -L peaks.narrowPeak / samtools view -c BAM. Обе пары reads учитываются как отдельные выравнивания, поэтому это не число фрагментов.

```
Команды (пример для 75ep; для 1–2ss и 14ss меняется префикс файлов):
samtools flagstat data/75ep/foxd3_75ep_chip.nuclear.bam
bamCoverage -b data/75ep/foxd3_75ep_chip.nuclear.bam -o results/signal/foxd3_75ep_chip.CPM.bw --normalizeUsing CPM --binSize 10 -p 4
bigwigCompare -b1 results/signal/foxd3_75ep_chip.CPM.bw -b2 results/signal/foxd3_75ep_input.CPM.bw --operation log2 --pseudocount 1 --binSize 10 -o results/signal/foxd3_75ep.log2_IP_Input.bw
macs3 callpeak -t data/75ep/foxd3_75ep_chip.nuclear.bam -c data/75ep/foxd3_75ep_input.nuclear.bam -f BAMPE -g 1360000000 -n foxd3_75ep -q 0.01 --outdir results/peaks
```

Вокруг вершин пиков были собраны матрицы computeMatrix reference-point ($\pm 2\,000$ п. н., бин 20 п. н., ChIP и Input), а по ним построены plotHeatmap и plotProfile. Графики для 5–6ss предоставлены вместе с данными.

Качество и число пиков

В предоставленных BAM все записи выровнены и корректно спарены; flagstat показывает ноль помеченных дубликатов. Это характеристика уже подготовленных файлов, а не оценка исходной библиотеки до фильтрации. Число пиков ниже получено из narrowPeak; для 5–6ss использован предоставленный преподавателем файл.

Стадия	ChIP, выравн.	Input, выравн.	Пики	FRiP	Макс. $-\log_{10}q$
75ep	23 863 894	39 931 858	36	0,0172 %	100,05
1–2ss	12 816 614	33 460 348	40	0,0140 %	56,18
5–6ss*	18 853 396	57 051 062	839	0,2360 %	163,70
14ss	41 553 880	27 794 668	170	0,1621 %	321,45

* Для 5–6ss числа взяты из frip.tsv и заголовка peaks.xls; в последнем Input указан как 28 525 531 парный фрагмент, то есть 57 051 062 выравнивания.

Больше всего пиков выявлено на 5–6ss. FRiP на этой стадии также выше, чем на 75ep и 1–2ss, хотя ChIP BAM на 5–6ss меньше по числу выравниваний, чем на 14ss. Максимальное $-\log_{10}q$ относится к одному самому значимому пику, а не к типичной силе связывания на всей стадии. Для сравнения: медианный fold_enrichment среди вызванных пиков равен 5,79; 6,11; 5,52 и 3,29 соответственно.

Профили обогащения вокруг вершин пиков

На рисунках 1–4 средний ChIP-сигнал сосредоточен около вершины пиков, а Input обычно ниже. Особенно отчётливо это видно на 5–6ss. Для каждой стадии график построен по её собственному набору пиков; шкалы по вертикали различаются, поэтому сравнивать точную высоту кривых между панелями напрямую нельзя.




Рисунок 1. Средний профиль ChIP и Input для стадии 75ep.




Рисунок 2. Средний профиль ChIP и Input для стадии 1–2ss.




Рисунок 3. Средний профиль ChIP и Input для стадии 5–6ss.




Рисунок 4. Средний профиль ChIP и Input для стадии 14ss.

Распределение сигнала у отдельных пиков

Heatmap показывает сигнал около каждой вершины (строка соответствует одному пик). Светлая центральная полоса на ChIP заметнее, чем на Input. На 5–6ss таких строк значительно больше; цветовые шкалы рисунков различаются.





Рисунок 5. Heatmap стадии 75ep.





Рисунок 6. Heatmap стадии 1–2ss.

5-6ss и 14ss




Рисунок 7. Heatmap стадии 5-6ss.




Рисунок 8. Heatmap стадии 14ss.

Сравнение участков между стадиями

Я считала два пика общими, если их координаты на одной хромосоме перекрывались хотя бы на одну пару оснований. Индекс Жаккара рассчитан по нуклеотидам: длина пересечения объединённых интервалов, делённая на длину их объединения. Это отличается от доли общих пиков при сильно разном числе пиков.

Пара стадий	Общих пиков	Жаккар по п. н.
75ep / 1–2ss	12	0,17371
75ep / 5–6ss	22	0,02271
75ep / 14ss	18	0,07514
1–2ss / 5–6ss	30	0,02813
1–2ss / 14ss	12	0,04264
5–6ss / 14ss	40	0,03694

Наиболее близкие наборы по Жаккару — 75ep и 1–2ss. Из 40 пиков 1–2ss 30 пересекаются с пиками 5–6ss, но обратная доля мала из-за большого набора на 5–6ss. Между 5–6ss и 14ss найдено 40 общих пиков.

Стадия	Пиков всего	Без перекрытия с любым из трёх остальных наборов
75ep	36	6
1–2ss	40	7
5–6ss	839	773
14ss	170	119

Если сравнивать только соседние 5–6ss и 14ss, специфичных к ним пиков соответственно 799 и 130. Эти числа отличаются от таблицы выше, где пик должен не перекрываться ни с одной из трёх других стадий. Отсутствие вызванного пика не доказывает полного отсутствия связывания: сигнал может не пройти порог q .

Три участка для проверки в IGV

На снимках IGV показано отношение ChIP к Input на логарифмической шкале и дорожки вызванных пиков для четырёх стадий. Для просмотра NC_007112.7, NC_007113.7 и NC_007117.7 переименованы соответственно в chr1, chr2 и chr6, как в геноме IGV. Координаты и значения сигнала не менялись; BigWig содержит данные только в трёх показанных окнах.

chr6:32203500-32210000

Сильнейший пик 5–6ss ($-\log_{10}q = 163,70$); интервалы вызваны и на трёх других стадиях.



Рисунок 9. Отношение ChIP/Input и вызванные пики в IGV для участка chr6:32203500-32210000.

chr2:33273000-33279000

Общий участок на всех четырёх стадиях; здесь находятся самые значимые пики 75ep и 1–2ss.




Рисунок 10. Отношение ChIP/Input и вызванные пики в IGV для участка chr2:33273000-33279000.

chr1:257000-263000

Пик 5–6ss с координатами 259734–260218 ($-\log_{10}q = 63,05$), не перекрывающий пики других трёх стадий.



Рисунок 11. Отношение ChIP/Input и вызванные пики в IGV для участка chr1:257000-263000.

Что означают файлы

Формат	Назначение в этой работе
GTF	Текстовая аннотация генов, транскриптов и экзонов с координатами.
BigWig (.bw)	Бинарная дорожка непрерывного сигнала; здесь CPM для ChIP/Input и $\log_2$ отношения.
BED	Таблица геномных интервалов с координатами chrom/start/end; например, вершины пиков.
narrowPeak	BED6+4: интервал пика, signalValue, $-\log_{10}(p)$, $-\log_{10}(q)$, смещение вершины.
peaks.xls	Текстовая таблица MACS3 с параметрами запуска, fold_enrichment и статистикой пиков.
matrix.gz	Сжатая матрица deepTools: сигнал вокруг вершин для heatmap и среднего профиля.

Вывод

С 75ep до 5–6ss число вызванных участков Foxd3 заметно возрастает, а к 14ss снижается. Для 5–6ss одновременно получены наибольшее число пиков, наибольший FRiP и хорошо выраженный средний ChIP-профиль. Часть участков сохраняется между стадиями, но перекрытие невелико, особенно при сравнении с большим набором 5–6ss.

Это согласуется с изменением ландшафта связывания Foxd3 при развитии нервного гребня. При этом точные доли «появившихся» и «исчезнувших» сайтов нельзя считать только биологическим эффектом: глубина секвенирования, качество ChIP, фон Input и порог вызова пиков влияют на результат. Без биологических повторов и дополнительной оценки качества нельзя уверенно отделить эти факторы. Сам ChIP-seq также не показывает, активирует или подавляет Foxd3 ближайший ген.